

Rodrigo Mendonça da Paixão  
Lucas Teles Agostinho

**Titulo a definir**

São Paulo – Brasil

2016

Rodrigo Mendonça da Paixão  
Lucas Teles Agostinho

## **Título a definir**

Pré-monografia apresentada na disciplina Trabalho de Conclusão de Curso I, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Centro Universitário Senac  
Bacharelado em Ciência da Computação

Orientador: Eduardo Heredia

São Paulo – Brasil

2016

# Lista de abreviaturas e siglas

GA	Algoritmos Genéticos
----	----------------------

# Sumário

<b>1</b>	<b>INTRODUÇÃO</b>	<b>4</b>
1.1	Motivação	4
1.2	Escopo	4
1.3	Justificativa	4
1.4	Objetivos	4
1.5	Método de trabalho	4
1.6	Organização do trabalho	4
<b>2</b>	<b>REVISÃO DE LITERATURA</b>	<b>5</b>
2.1	Busca de caminhos	5
2.1.1	O Algoritmo A*	5
2.1.2	Aplicações	7
2.2	Algoritmos genéticos	8
2.3	Algoritmos de busca paralelo	8
2.4	Algoritmos genéticos para busca de caminhos	8
2.5	Algoritmos genéticos paralelos ou distribuídos para busca de caminhos	8
<b>3</b>	<b>PROPOSTA</b>	<b>11</b>
<b>4</b>	<b>CRONOGRAMA</b>	<b>12</b>
	<b>REFERÊNCIAS</b>	<b>13</b>

# 1 Introdução

## 1.1 Motivação

O problema de buscar o melhor caminho entre dois pontos tem uma grande importancia em problemas da engenhria e ciencia, tais como rotear o trafico de telefone, navegar por um labirinto ou mesmo definir o layout de trilhas impressas em uma placa eletronica.

Busca de caminhos tambem tem uma grande importancia no ambito dos jogos digitais, clara em jogos aonde um jogador compete ou coopera com uma inteligencia artificial, como jogos de tiro em primeira pessoa e de estrategia em tempo real.

O Valor de entretenimento do jogo pode ser drasticamente reduzido quando os personagens nao podem atravessar um mapa complexo de forma competente. As vezes deixando visivelmente claro para o jogador a sua incapacidade de lidar com a busca de caminho de forma satisfatoria.

Ainda é comum em jogos digitais termos mais de um agente de busca de caminho ao mesmo tempo no mesmo cenario, podendo ser muitas vezes muitos custoso computacionalmente falando. Por isso varios desenvolvedores de jogos tem juntado esforços para desenvolver soluções de busca de caminho em ambientes de recursos escassos. ([PONTEVIA, 2008](#))

## 1.2 Escopo

## 1.3 Justificativa

## 1.4 Objetivos

## 1.5 Método de trabalho

## 1.6 Organização do trabalho

## 2 Revisão de Literatura

### 2.1 Busca de caminhos

#### 2.1.1 O Algoritmo A\*

O algoritmo A\* é um dos mais populares soluções no ramo de busca de caminhos, o algoritmo garante achar o menor caminho entre dois pontos (HART; RAPHAEL, 1968), porem gera uma grande arvore de busca nos processos, consumindo muito tempo e memoria, é comum haver modificações no algoritmo para explorar uma arvore de busca menor, diminuindo o tempo para achar um caminho sacrificando a garantia de se encontrar o melhor caminho no final. (BOTEÁ, 2004).

O algoritmo A\* em sua forma tradicional, utiliza a formula heurística  $f(n) = g(n) + h(n)$ , onde  $g(n)$  é o custo para chegar ao nó  $n$ , e  $h(n)$  é o custo estimado para atingir o nó de destino a partir do nó  $n$ . Este cálculo pode ser realizado pela distância Manhattan. Para cada iteração sobre os vizinhos do nó atual é calculado o  $f(n)$  e adicionado em uma lista de nós abertos (A). Depois é verificado na lista o menor valor de  $f(n)$ , este é removido, adicionado a lista de nós fechados (F) e a partir desse ponto, ele se torna o nó atual, quando o nó atual é o mesmo nó de destino o algoritmo retorna o caminho encontrado, assim podemos encontrar a solução ideal .

Podemos aplicar o algoritmo A\* em um Grafo direcionado ponderado facilmente (Figura 1)




Figura 1 – Grafo para busca (HART; RAPHAEL, 1968)

**Figura 1** Consiste em um nó inicial  $s$  e mais três outros nós ( $n_1, n_2, n_3$ ). As arestas contêm a direção e o custo do trajeto. Se partirmos do algoritmo  $A^*$  para produzir um subgrafo do melhor caminho, partindo de  $s$  podemos ir para  $n_1$  e  $n_2$ , os valores de  $g(n_1)$  e  $g(n_2)$  são respectivamente 3 e 7. Supondo que  $A^*$  expanda  $n_1$ , sucedido por  $n_2$  e  $n_3$ , nesse ponto  $g(n_3) = 3 + 2 = 5$ , o valor de  $g(n_2)$  é diminuído pois um caminho de menor custo foi encontrado  $3 + 3 = 6$ , o valor de  $g(n_1)$  continua sendo 3.

A heurística fornece uma expansão considerável dos nós, que são mantidos na memória durante todo o processamento. (Figura 2)




Figura 2 – Exemplo de  $A^*$  (SANTOS, 2012)

### 2.1.2 Aplicações

Aplicações para os algoritmos de busca podem ser diversos, como por exemplo, em um simulador de carro corrida (WANG; LIN, 2012). Utilizando o algoritmo do  $A^*$  com duas modificações para encontrar o melhor caminho enquanto evita os obstáculos entre o ponto de início e o ponto de destino. A primeira modificação consiste em utilizar o Teorema de Triângulos de Pytagoras, onde primeira calcula a distancia entre dois pontos(1 e 2), verifica se existe algum obstaculo dentre eles, se existir, utiliza o terceiro ponto para calcular a Hipotenusa e verifica se existe obstaculo entre a hipotenusa, se não existir, remove o ponto 2 e começa a considerar o caminho do ponto 1 para o ponto 3. A segunda modificação

O projeto utiliza 3 pistas reais de corrida de Formula 1,Peru,Itália e Hungria, sendo cada pista, uma imagem de escala 1280x782 pixels retiradas do site oficial da Formula 1. O Carro é implementado em Microsoft XNA Game Studio, plataforma usada para desenvolver jogos para Windows Phone,Xbox e Windows. As Imagens das pistas são modificadas para serem mapas de detecção de colisão, a pista é pintada de preto, indicando onde o carro pode andar e o resto pintado de branco indicando os o carro não pode andar. O  $A^*$  considera 4 nós adjacentes (cima,baixo,esquerda e direita). O carro tem o tamanho



de 18x12 pixels e uma movimentação de 2 pixels por segundo. Como o XNA trabalha com uma taxa de quadros de 60 quadros por segundo, o carro se movimenta a 120 pixels por segundo.

## 2.2 Algoritmos genéticos

## 2.3 Algoritmos de busca paralelo

## 2.4 Algoritmos genéticos para busca de caminhos

Buscando melhorar a eficiência dos algoritmos de busca, foram criadas formas híbridas, levando os algoritmos genéticos analisarem todo o percurso, ajudando o algoritmo de busca em momentos que a próxima ação é incerta.

Utilizando o algoritmo de busca BFS (*Best First Search*), foi desenvolvido o modelo PPGA (*Patterned based Pathfinding with Genetic Algorithm*). O modelo utiliza algoritmos genéticos como um módulo para calcular os sub caminhos ao longo do processo de busca, cada vez que o módulo é chamado, herda informações da chamada anterior, tendo um ganho considerado de desempenho. O módulo é chamado, quando nenhum dos valores dados pelo BFS são melhores que o valor atual. Os resultados da análise do PPGA foram bons, por encontrar boas soluções em um curto período de tempo, mostrando ser muito bom para mapas onde o percurso segue um padrão, mas perdendo para o BFS para mapas mistos ou que não seguem o mesmo padrão ao longo o percurso, considerando o modelo como promissor, indicando que mudanças nos parâmetros do algoritmo genéticos, pode melhorar o desempenho dos testes ([SANTOS, 2012](#)). Um outro método, utiliza o algoritmo de busca A\* (*AStar*)

## 2.5 Algoritmos genéticos paralelos ou distribuídos para busca de caminhos

Foi demonstrado que algoritmos genéticos paralelos são eficientes para a resolução de problemas de busca de caminho, tal como o clássico problema do caixeiro viajante, que consiste em dado um numero finito de cidades com seus custos de viagem entre elas, deve-se encontrar o caminho mais curto para viajar entre todas as cidades e voltar ao ponto inicial. O problema pode ser representado pelo modelo de um grafo direcionado ponderado, aplicando a mesma ideia, o problema seria encontrar o caminho de menor custo para percorrer todos os nós, de maneira análoga, as cidades seriam os nós e a distancia entre elas, o peso das arestas ([D.LOHN SILVANO P. COLOMBANO, 2000](#))([ALAOUI; EL-GHAZAWI, 2000](#))([MUHLENBEIN, 2000](#)).

Os algoritmos genéticos exigem apenas o valor dado por uma função objetivo como parâmetro e mesmo sobre espaços de busca grandes, tem uma convergência rápida. Por causa do processo associado, agrega uma visão mais global do espaço de busca na prática de otimização e possuem uma fácil paralelizar por causa da independência dos seus processos. Em comparação com as técnicas de busca mais comuns, que requerem informações derivadas, continuidade do espaço de busca ou conhecimento completo da função objetiva. (MOLE, 2002).

A solução para este tipo de problema pode requer uma quantidade grande de processamento. Uma boa solução seria dividir o processamento do problema em pequenas partes e distribuir cada parte para um processador a parte, trabalhando de forma distribuída ou paralela. Vários modelos para essa finalidade foram propostos.

Um modelo interessante para paralelização seria o de mestre-escravo, onde o mestre fica responsável na manutenção da população e execução dos operadores genéticos. A avaliação dos melhores indivíduos é distribuída para os demais escravos, O mestre envia um indivíduo a cada um dos escravos subjacentes. Cada escravo realiza a interpretação do problema, aplica a função de cálculo para a escolha dos melhores indivíduos e envia seus resultados ao mestre, que executa seleção dos indivíduos e a geração da nova população, repetindo o processo como um todo. Essa estrutura teve implicação satisfatória para a automação de design de circuitos eletrônicos. (D.LOHN SILVANO P. COLOMBANO, 2000)

Outra forma de trabalhar com o modelo de mestre escravo, seria definir que cada um dos nós escravos subjacentes fica responsável por sua própria população. O nó central mestre, cria as populações iniciais e as distribui para os nós escravos. Cada nó escravo processa a evolução da população por um determinado número de gerações e então a submete ao mestre. O mestre então seleciona os melhores indivíduos dentre todas as populações dos nós escravos e os distribui novamente. Em cada nó escravo, os novos indivíduos distribuídos pelo mestre são inseridos na população corrente e o processo de evolução recomeça. A migração entre os escravos, que é controlado pelo nó mestre, implementa o mecanismo que regula a velocidade da convergência e oferece os meios de escape dos mínimos locais. Entretanto a migração das populações dos nós escravos para o mestre e vice versa pode impor um certo grau de sobre carga, dependente do meio de comunicação entre os nós. Esse modelo obteve sucesso no mapeamento de tarefas em máquinas paralelas. (ALAOUI; EL-GHAZAWI, 2000)

Podemos partir do ponto que cada indivíduo é o responsável por encontrar e reproduzir com um parceiro em sua vizinhança. O controle de seleção e reprodução se espalha pela população e o algoritmo deixa de ser centralizado em um mestre, com isso, diminui o grau de sincronização e facilita a paralelização. O processo do algoritmo é definir uma representação genética para o problema e criar a estrutura de vizinhança e

sua população inicial. Cada indivíduo faz uma busca em sua vizinhança e seleciona um parceiro para a reprodução. Uma geração descendente é criada com o operador genético resultante. (MUHLENBEIN, 2000)

Podemos observar alguns problemas nos modelos apresentados (MOLE, 2002), no modelo de (D.LOHN SILVANO P. COLOMBANO, 2000) existe problema em explorar o paralelismo no cálculo de verificação dos indivíduos não explorando para a reprodução e mutação. No modelo de (MUHLENBEIN, 2000), tem a possibilidade de utilizar vários métodos de busca de indivíduos da mesma população, sendo úteis em casos que a eficiência dos métodos de busca se mostram dependentes da instância do problema. O modelo (ALAOUI; EL-GHAZAWI, 2000), por todos os escravos devem enviar para o nó mestre, demanda uma grande capacidade de processamento no nó mestre, e proporciona a divisão das populações em pequenas ou de médio porte.

(MOLE, 2002) desenvolveu seu próprio modelo, utilizando o modelo de (ALAOUI; EL-GHAZAWI, 2000) como inspiração. O modelo segue o conceito mestre-escravo, o mestre cria as populações e distribui a cada uma delas, os conjuntos de genes e parâmetros iniciais. O mestre é utilizado para a troca de indivíduos entre as populações, mantendo um indivíduo de cada população até serem substituídos por um melhor e envia esses indivíduos para as populações que não seja a sua de origem. As populações são independentes, gerando seus indivíduos iniciais com base nos genes enviados pelo mestre, aplicando seus próprios operadores de evolução e a população que determina os parceiros dos indivíduos.

## 3 Proposta

## 4 Cronograma

Para modelar a proposta descrita, sera seguido um cronograma semanal, este ira descrever semana a semana as tarefas que devem ser realizadas de forma a se concluir o trabalho.

Semana	Atividade
1 <sup>a</sup>	Analise de trafego de pacotes em rede, criar aplicação em Go para ler e realizar log das operações na rede
2 <sup>a</sup>	Criar base de dados de trafego em rede de forma controlada. Verificar como implementações de IDS atuais reagem a esses dados. / trabalhar na monografia
3 <sup>a</sup>	Implementar na aplicação de log de trafego um sistema de redes neurais
4 <sup>a</sup>	Realizar treinamento da RNA da aplicação com os <i>datasets</i> KDD'99 e o modelado para o projeto / trabalhar na monografia
5 <sup>a</sup>	Mensurar resultados da aplicação do modelo / trabalhar na monografia
6 <sup>a</sup>	Comparar com os resultados obtidos por outros IDS, e com resultados publicados de outros modelos baseados em RNA
7 <sup>a</sup>	Analisar se for possível como aprimorar os resultados do modelo
8 <sup>a</sup>	Implementar o modelo de POLVO-IIDS
9 <sup>a</sup>	Comparar com os resultados obtidos anteriormente / trabalhar na monografia
10 <sup>a</sup>	Implementar RNA clusterizado.
11 <sup>a</sup>	Comparar com os resultados obtidos anteriormente / trabalhar na monografia
13 <sup>a</sup>	Implementar modelo hibrido POLVO-IIDS Clusterizado
14 <sup>a</sup>	Comparar com os resultados obtidos anteriormente / trabalhar na monografia
15 <sup>a</sup>	Trabalhar na monografia - desenvolvimento
16 <sup>a</sup>	Trabalhar na monografia - resultados
17 <sup>a</sup>	Trabalhar na monografia - resultados
18 <sup>a</sup>	Apresentação dos resultados

# Referências

- ALAOUI, O. F. S. M.; EL-GHAZAWI, T. A parallel genetic algorithm for task mapping on parallel machines. 2000. Citado 3 vezes nas páginas 8, 9 e 10.
- BOTEA, M. M. A. Near optimal hierarchical path-finding. *Journal of Game Development*, Vol. 1, p. 7–28, 2004. Citado na página 5.
- D.LOHN SILVANO P. COLOMBANO, G. L. H. t. D. S. J. Parallel genetic algorithm for automated electronic circuit design. 2000. Citado 3 vezes nas páginas 8, 9 e 10.
- HART, N. J. N. P. E.; RAPHAEL, B. A formal basis for the heuristic determination of minimum cost paths. *IEEE Transactions on Systems, Science, and Cybernetics*, SSC-4, p. 100–107, 1968. Citado 2 vezes nas páginas 5 e 6.
- MOLE, V. L. D. Algoritmos genéticos – uma abordagem paralela baseada em populações cooperantes. 2002. Citado 2 vezes nas páginas 9 e 10.
- MUHLENBEIN, H. Evolution in time and space - the parallel genetic algorithm. 2000. Citado 2 vezes nas páginas 8 e 10.
- PONTEVIA, P. Pathfinding is not a star. *Autodesk, white paper*, p. 1–6, 2008. Citado na página 4.
- SANTOS, A. F. V. M. e. E. W. G. C. U. O. Pathfinding based on pattern detection using genetic algorithms. *SBC - Proceedings of SBGames*, 2012. Citado 2 vezes nas páginas 7 e 8.
- WANG, J.-Y.; LIN, Y.-B. Game ai: Simulating car racing game by applying pathfinding algorithms. *International Journal of Machine Learning and Computing*, v. 2, 2012. Citado na página 7.